

Projet : Pr vision m t o en Australie

Apprenants : Amrane Iris, Jean-Paul Santoni, Louis Boudry

Lien d p t Git : <https://github.com/OuroborosVD/Rapport-m-teo-australie.git>

Base de donn es : WeatherAUS

Etape 2 : Rapport de mod lisation

A. Pr paration des donn es pour les mod les

Une fois la base nettoy e, nous s parons les donn es en **train et test**.

La dimension temporelle ayant  t  perdue lors de l'encodage, nous la reconstituons pour respecter l'ordre chronologique :

- **Train :** Toutes les donn es sauf les 12 derniers mois
- **Test :** les **12 derniers mois**

Une fois la s paration effectu e, nous corrigeons le probl me de d s quilibre de classe uniquement sur la partie train. Pour ce faire, nous utilisons une m thode d'undersampling : RandomUnderSampler. On contr le que les classes soient bien  quilibr es une fois undersampling exploit  :

- Avant undersampling : taux de jour de pluie (RainTomorrow =1) $\approx 22\%$
- Apr s undersampling : taux de positif $\approx 44.4\%$

B. Pr sentation des mod les et premiers r sultats

Nous testons trois mod les :

- **Un mod le de r gression logistique :** mod le de r f rence, interpr table, seuil ajustable
- **Un mod le Randomforest :** performant sur donn es tabulaires, importance des variables.
- **Un mod le Gradient Boosting :** performant, bon pour capturer des relations fines

On obtient les r sultats suivants :

- Pour la r gression logistique : F1 (classe pluie=1) : 0.6045158053186152
- Pour le Randomforest : F1 (classe pluie=1) : 0.6389971557990098
- Pour le gradient boosting F1 (classe pluie=1) : 0.6255271920088791

Les scores  tant proches, une optimisation est n cessaire pour augmenter leur pr cision. Nous allons nous concentrer sur les deux mod les les plus performants.

C. Optimisation des mod les

1. Le RandomForest
- a. Pistes d'optimisation

Pour le RandomForest nous envisageons :

- Créer une validation temporelle (les deux derniers mois de la base train) ; car notre variable cible peut varier fortement selon la période de l'année.
- Déterminer le seuil de décision adapté, afin de transformer les probabilités en fonction de notre priorité : détecter les jours de pluie tout en limitant les faux positifs.
- Réentraîner le modèle sur l'ensemble de la base train, puis l'évaluer une seule fois sur la base test, afin d'éviter de fausser le modèle.

b. Résultats et interprétations

Nous retestons le modèle avec ces nouveaux paramètres. Le seuil de décision retenu après validation est de 0,64.

Les performances globales du modèle sont :

- F1 "pluie" = 0,63
- Précision "pluie" = 0,68
- Rappel "pluie" = 0,59
- Accuracy = 0,84

On en conclut que le compromis obtenu avec ce seuil de décision est satisfaisant :

- La précision du modèle s'améliore, il se trompe moins souvent ; mais le rappel reste bas donc une partie des jours de pluie est encore manquée.
- Les variables les plus explicatives sont cohérentes : le taux d'humidité et la pression à 15h.

2. Le modèle de GradientBoosting

- a. Pistes d'optimisation

Pour ce modèle, nous avons envisagé les optimisations suivantes :

- Reprendre la validation chronologique comme sur le modèle RandomForest : on crée une base de validation (2 derniers mois) au sein du jeu d'entraînement
- Rééquilibrer légèrement les classes sur la base train pour améliorer la détection des jours de pluie.
- **Ajuster les paramètres clés :**

- **Le taux d'apprentissage** : le diminuer tout en augmentant le nombre d'arbres afin d'obtenir un apprentissage plus progressif et avoir une meilleure généralisation.
- **Profondeur des arbres et taille minimale des feuilles** : les réduire pour limiter le surapprentissage.
- **Sous-échantillonnage aléatoire** : pour réduire la variance et augmenter la robustesse du modèle.
- **Choix du seuil de décision** : sur la base de validation afin d'adapter le compromis précision/rappel
- **Réentraînement sur l'ensemble de la base train, puis évaluation une seule fois sur la base test** pour garantir une mesure fiable des performances.

b. Résultats et interprétations

Le seuil de décision retenu après validation est de 0,68.

Les performances globales du modèle sont :

- F1 "pluie" = 0,63
- Accuracy "pluie" = 0,70
- Rappel "pluie" = 0,58
- Accuracy globale = 0,84

Les résultats sont assez similaires à celui de RandomForest. Le modèle se trompe moins souvent, mais il manque encore de nombreux jours de pluie.

Les variables explicatives sont principalement l'humidité, suivie du **vent**. Ce qui est cohérent avec un phénomène dépressionnaire et annonciateur de pluie (humidité élevée et vent fort)

Notre objectif est désormais d'augmenter le rappel sans trop dégrader la précision. Pour cela, nous allons passer à un modèle HistGradientBoostingClassifier, réputé pour sa rapidité d'exécution et ses performances sur les grands ensembles de données.

3. Le modèle HistGradientBoostingClassifier

a. Pistes d'optimisation

Les paramétrages envisagés sont :

- **Ajuster le seuil de décision** afin d'améliorer le rappel tout en conservant une bonne précision.
- **Ajouter des features de mémoire** des deux derniers jours (variables explicatives de la pluie le jour J) par station météo (variable location) pour optimiser les gains

de rappel sans pertes de précision. En effet le croisement entre les données historiques obtenues sur la station météo et sa localisation à des chances d'améliorer grandement notre modèle.

b. Résultats et interprétations

La rapidité de calcul est nettement supérieure avec ce modèle. Le seuil de décision retenu est de 0,69.

Les résultats obtenus sont :

- F1 "pluie" = 0,69
- Accuracy "pluie" = 0,71
- Rappel "pluie" = 0,67
- Accuracy globale = 0,86

Les performances du modèle sont nettement supérieures aux précédentes. Le modèle détecte davantage de jours de pluie tout en commettant moins d'erreurs.

Conclusion :

Notre problématique était de pouvoir prédire s'il pleut le lendemain ou non. Après plusieurs essais et tests de différents modèles, il semble que notre modèle **HistGradientBoosting**, optimisé grâce à l'ajout de variables de mémoire et à l'ajustement du seuil de décision, fournit des résultats satisfaisants.

Modèle	Seuil	F1 pluie	Précision pluie	Rappel pluie	Accuracy
Random Forest	0,64	0,63	0,68	0,59	0,84
Gradient Boosting	0,68	0,63	0,7	0,58	0,84
HistGradientBoosting	0,69	0,69	0,71	0,67	0,86